Stanford Encyclopedia of Philosophy: Game Theory and Ethics by Verbeek, Bruno and Morris, Christopher

translated by Alexey Shrub aka worldmind with translate.google.com
http://mindstate.info

17 мая 2017 г.

1 Введение

Теория игр это наука о независимом рациональном выборе. Её следует отличать от теории принятия решений, в которой исследуется принятие индивидуальных решений, решений, которые принимаются независимо от решений других агентов. Теория принятия решений также применяется в этике, см. Dreier 2004; Mele and Rawlings 2004.

Теория игр может использоваться для объяснения, предсказания и оценки человеческого поведения в ситуациях, в которых результат действий зависит от поведения нескольких агентов и где выбор модели поведения каждого агента зависит от модели поведения остальных агентов. Следовательно теория игр пересекается с этикой и используется различными способами в этике и политической философии.

Мы сосредоточимся на влиянии и использовании теории игр в этике и тех частях политической теории, которые связаны с нормами или принципами справедливости, игнорируя вопросы

о политических и правовых институтах, с одной стороны, и вопросы о проблемах, связанных с моральными добродетелями, с другой.

В литературе встречается три различных подхода к применению теории игр в этике. Первый мы назовём функционализмом, в нём теория игр используется для определения функции морали. В нём описываются проблемы возникающие при отсутствии морали из наличия которых делается вывод о исправляющей и улучшающей функции морали. Второй подход, контрактуализм, использует теорию игр (в первую очередь теорию переговоров) для формализации теории социального контракта. Эта теории исходит из того, что социальные нормы или институты оправданы настолько, насколько рациональные агенты добровольно согласились с ними по причине осознания взаимной выгоды. Теория переговоров может быть использована, во-первых, для определения того, что можно считать соглашением в данных условиях, а во-вторых, для предсказания результатов переговорного процесса. В третьем подходе, теория игр (в первую очередь эволюционная теория игр) используется «восстановления» многих моральных норм и практик. Далее мы рассмотрим каждый из этих подходов, их результаты и проблемы с которыми они столкнулись. Но начать необходимо с небольшого экскурса в историю.

2 История

В 1954 году британский философ Ричард Брейтуэйт (Richard Braithwaite) дал свою вступительную лекцию под названием «Теория игр как инструмент для морального философа» (Braithwaite, 1955). В своей лекции Брейтуэйт утверждал, что многие вопросы о распределительной справедливости имеют ту же структуру, что и «переговорная проблема». Эта проблема была проанализирована несколькими годами ранее Джоном Нэшем, более поздним лауреатом Нобелевской премии, с использованием теории игр (Nash 1950). Брейтуэйт предсказал, что теория игр корен-

ным образом изменит моральную философию. Его предсказание появилось менее чем через десять лет после публикации «Теория игр и экономического поведения» Джона фон Неймана и Оскара Моргенштерна - книги, которая породила совершенно новую отрасль социальных наук и прикладной математики (Von Neumann and Morgenstern 1944).

Применение теории игр в этике было не совсем новым явлением. Теоретико-игровые идеи можно найти, например, в работах Томаса Гоббса и Дэвида Юма (см. Gauthier 1969; Kavka 1986; Hampton 1986; Vanderschraaf 1998). Тем не менее предсказание Брейтуэйта не сбылось. Теория игр пока не изменила фундаментально этику. Спустя десять лет после Брейтуэйта Брайан Барри опубликовал «Политический аргумент», а спустя несколько лет вышла основополагающая работа «Соглашение» Дэвида Льюиса (Barry 1965; Lewis 1969). В конце 60-х вышла первая из серии публикаций Дэвида Готье. В них он использовал теорию игр для развития своей моральной теории (Gauthier 1967). Однако до недавнего времени влияние теории игр в этике не было столь же значительным, как в социальных науках вообще. Несмотря на это неуверенное начало, применение теории игр в моральной философии привело к постоянному увеличению потока важных публикаций.

3 Функционализм

Теория игр была использована для анализа функции морали. Хорошим примером является появление Эдны Ульман-Маргалит «Появление норм», в которой она утверждает, что моральные нормы позволяют агентам сотрудничать и координировать свои действия в ситуациях, когда преследование собственных интересов мешает этому (Ullmann-Margalit 1977). Ее классический пример - это два артиллериста, которым грозит выбор: бежать от наступающего врага или оставаться и управлять своим оружием. Их пушка расположена в стратегически важном проходе.

Если оба остаются, у них есть значительный шанс получить ранения, но несомненно, что продвижение противника будет остановлено. Если оба будут бежать, противник сможет взять горный перевал, настигнуть и захватить их. Если только один из них останется, а другой убежит, храбрый артиллерист умрет в бою, но у другого стрелка будет достаточно времени, чтобы сбежать безопасно. Предположим, что оба пытаются пережить это испытание, желательно невредимыми, тогда у каждого солдата есть причина бежать. Причина этого в том, что они занимаются дилеммой заключенного (см. 1). У каждого наводчика есть выбор - убежать или остаться и бороться. Этот выбор представлен в строках для стрелка #1 и столбцах для стрелка #2. Каждая ячейка в матрице представляет результат пары выборов. Число в нижнем левом углу каждой ячейки показывает, как наводчик #1 оценивает этот результат по сравнению с другими возможными результатами - в условных единицах «полезности». Число в правом верхнем углу представляет рейтинг этого результата на #2.

		artillerist #2	
		stay	*flee*
artillerist #1	*stay*	2 2	3 0
	flee	0 3	1 1

Рис. 1: Prisoner dilemma

Рассмотрим случай #1. Предположим, что #2 решает остаться и сражаться. В таком случае, #1 лучше бежать. Он выживет, не пострадав. В формальном представлении матрицы он обеспечит более высокий рейтинг (3, а не 2). Предположим, что #2 решает бежать, тогда и #1 лучше всего бежать. Он выживет в битве, хотя он будет заключен в тюрьму на время войны. Если бы он остался и сражался, он бы точно умер, а убегая, он получит более высокий рейтинг (1 вместо 0). Наводчик #2 находится в том же положении, что и #1: для него также, как и для другого, лучшая стратегия всегда бежать. Как видим, каждому отдельному стрелку было бы лучше убежать, независимо от того, что делает другой. Тем не менее, верно, а для некоторых, парадоксально, - что обеим было бы лучше, если бы оба стояли на своих местах. Результат индивидуально рационального действия является Парето-неэффективным (или субоптимальным).

Предположим, что оба понимают суть своего затруднительного положения. Поскольку они видят, что у каждого есть веские причины убежать, они могут попытаться исключить эту возможность. Например, они могли бы приковать друг друга к пушке для предотвращения бегства. Ульман-Маргалит показал, что положение артиллеристов (дилемма заключенного) является структурным эквивалентом многих повседневных взаимодействий, управляемых моралью. Более того, так же, как взаимное сцепление обязывает артиллеристов оставаться и сражаться, нравственность обязывает агентов избегать Парето-неэффективных или неоптимальных результатов. С этой точки зрения функция нравственности заключается в предотвращении ошибок рациональности (Mackie 1977).

4 Проблемы функционализма

Есть несколько проблем с функциональным анализом морали. Во-первых, это известные проблемы с функциональными объяснениями в социальных науках. Тот факт, что приня-

тая практика или учреждение выполняют определённую функцию не объясняет ни его происхождения, ни его сохранения. Например, можно утверждать, что функция общественной системы образования обучать молодёжь, функция государства обслуживать интересы правящего класса, а функция религии поставлять опиум для народа. Однако, это утверждение нельзя считать объяснением до тех пор пока, не будет показано, что именно эти системы являются причиной, механизмом выполнения этих функций. *От переводчика: если я правильно понял, то можно привести такое пояснение - то что мы думаем, что система образование учит людей совершенно не означает, что это так, это нужно доказать, ведь вполне возможно, что люди учатся самостоятельно или друг у друга или на первой работе, а система образования в этом мало помогает, а может и мешает, заставляя тратить своё время на посторонние вещи, одним из способов узнать это убрать систему образования и посмотреть, что получится, снизится ли уровень квалификации или нет.* Аналогично, даже если моральные нормы помогают достичь Парето-оптимума, которого не удаётся достичь нескоординированным рациональным выбором, это не объясняет существование и постоянство морали, до тех пор пока не будет показано, что именно мораль мотивирует людей поступать определённым образом.

Во-вторых, открытым остаётся вопрос о том совпадает ли мораль со взаимной выгодой или Парето-оптимумом. Многие мыслители утверждают, что часто мораль вынуждает нас действовать невыгодным для всех образом. Очевидным примером может быть запрет на продажу себя в рабство. Это может быть выгодно как для раба, так и для хозяина (раб сможет расплатиться по долгам, а хозяин избавится от домашней работы), однако это запрещено и моралью и законами. *От переводчика: На самом деле это бестолковый пример - чтобы заработать не нужно быть рабом, достаточно быть работником, никакой выгоды от рабского статуса в данном примере нет. Да и ссылка на безвестных многих мыслителей не вызывает уважения.*

В-третьих, функционалистский подход исходит из того, что требования морали конфликтуют с индивидуальной рациональностью. Предполагается, что мораль должна решить проблему проблему неоптимальности по Парето возникающую в результате независимых рациональных решений индивидов. В функционалистском подходе моральные агенты кажутся нерациональными (за исключением ситуаций сожаления или избегания вины). Напрашивается вопрос «Зачем быть моральным?». Функционализм исключает ответ на этот вопрос. *От переводчика: Не очень ясный момент, видимо речь о том, что рациональные индивиды без всякой морали понимают как найти оптимальное по Парето решение, а если не могут и им нужна мораль, то значит не такие уж они и рациональные. А раз не достаточно рациональные, то им не очень понятен рациональный аргумент в пользу морали, которая помогает выбрать рациональное решение. Тут можно возразить следующим образом - для рациональных агентов мораль это как набор ранее доказанных теорем, который позволяет делать выводы из них, не повторяя их доказательства. Мораль экономит усилия на совершение рационального выбора.*

В-четвёртых, цели функционалистского подхода не представляют значительного интереса для теоретиков морали. Функционализм сосредоточен на поиске объяснения происхождения и сохранения моральных норм и практик. Моральные теоретики меньше интересуются такими вопросами, а сосредоточены на том что мы должны делать. Именно мораль как руководство к действию и к жизни является главным интересом морального философа. Допустим, что есть правдоподобное функциональное объяснение конкретных моральных норм. Означает ли это, что я обязан следовать этим нормам если они применяются ко мне? Кажется есть разница между определением функции морали и выяснением того какого конкретного набора моральных норм мы должны придерживаться. Не очень ясно как на этот вопрос отвечают сторонники функционалистского подхода. *От переводчика: Не уверен что это возражение обосновано, конечно выбор*

морали произволен, но функционалистский подход как раз и говорит, что мы должны взять ту мораль, которая позволяет решать проблему поиска оптимума по Парето. И мы должны её использовать, если хотим жить в обществе и эффективно сотрудничать.

5 Теория переговоров и контрактуализм

Как мы видели выше, одно из претензий к функционализму заключается в том, что он не объясняет связи между индивидуальным выбором и возникновением и сохранением моральных норм. Мораль вводится как нечто вне индивидуального рационального выбора. В ответ на эту трудность многие теоретики пытались понять нравственность как результат индивидуального рационального выбора. Приблизительно мы можем выделить две стратегии. Во-первых, есть те, кто моделирует мораль в результате однократного выбора очень большого набора агентов, морального сообщества. Во-вторых, есть те, кто подходит к морали в результате серии повторяющихся мелкомасштабных взаимодействий. Мы обсудим этот второй подход в разд. 8. Здесь мы обсудим подход, который рассматривает мораль как предполагаемый результат взаимодействия между рациональными агентами при одинаково идеальных обстоятельствах. Это старая идея в моральной и политической философии: это идея социального контракта. Мораль интерпретируется как результат процесса переговоров.

Введение теории игр, особенно тех частей теории, которые связаны с переговорами (так называемая кооперативная теория игр и теория переговоров), стимулировало интерес к теории социального контракта за последние десятилетия. Джон Харсани, Ричард Брэйтвейт, Джон Роулз, Брайан Барри и Дэвид Готье (John Harsanyi, Richard Braithwaite, John Rawls, Brian Barry, and David Gauthier) использовали теорию игр и теорию принятия решений для формулирования своей версий теории (Harsanyi 1955;

Braithwaite 1955; Barry 1965; Rawls, 1971; Gauthier, 1986). Ссылаясь на теорию переговоров, они попытались показать:

1. что рациональные агенты в подходящей идеализированной переговорной ситуации согласуют конкретное, уникальное распределение преимуществ сотрудничества;

2. как выглядит это распределение;

3. что это распределение определяет как справедливость;

4. что рациональные агенты будут соблюдать условия сделки (в случае с Готье).

Для этих теорий важно, как именно характеризуется переговорная ситуация. Готье, как и многие другие, думает о ней как о дилемме заключенного. То есть, затруднительное положение сторон в идеальном переговорном положении структурно эквивалентно ситуации артиллеристов, которую мы описывали выше. Без какого-либо сотрудничества артиллеристы обречены бежать и провести оставшуюся часть войны в плену. Предположим, что в этой ситуации можно заключить обязывающие соглашения. Решает ли это проблему угрозы Парето-неэффективности? Нет, потому, что не ясно, как будут распределены выгоды от сотрудничества. Может показаться, что в этом случае есть только один способ, которым они могут быть распределены, но это обманчивое впечатление. Артиллеристы могли решить следовать смешанной стратегии. Смешанная стратегия - это лотерея поверх доступных стратегий каждого индивида. Например, артиллеристы могут решить бежать с вероятностью, скажем, $1/3$ и остаться и сражаться с вероятностью $2/3$. (Следует отметить, что идея смешанной стратегии обычно вводится в контексте так называемой кардинальной полезности, ранее числа в матрице (0, 1, 2 и 3) только обозначали ранжирование результата, а теперь предполагается, что числа предоставляют некоторую информацию об относительном ранжировании результата. Например, полезность «2» кооперативного результата означает, что агент безразличен

между этим результатом и попыткой, в которой с вероятностью 1/3 будет получен результат «0» (худший результат), а также попыткой, в которой с вероятностью 2.3 будет получен результат «3» (лучший результат) (подробное обсуждение кардинальной теории полезности см. в разделе 3.5 статьи о толкованиях вероятности, а также статью о Санкт-Петербургском парадоксе). Начиная с этого момента, мы предполагаем, что числа в матрице обозначают такую кардинальную полезность.)

Артиллеристы понимают, что каждый из них в отдельности может реализовать хотя бы один, но худший результат отказа от сотрудничества. Это означает, что результат их соглашения должен быть по меньшей мере столь же хорош, как и результат, не связанный с сотрудничеством. Поэтому распределение, с которым они согласятся, должно быть не менее 1. Предположим, что у канониров есть пара игральных костей. Теперь они могут реализовать кооперативные распределения, отличные от 2. Например, если они согласны бросить оба кубика, и если сумма окажется 6 или меньше, то # 1 будет бежать (таким образом, реализуя значение полезности 3). Однако, если сумма обоих костей больше 6, # 1 останется и сразится с врагом (получая худший результат равный 0). Ожидаемая полезность этой сделки для # 1 равна $5/12*3+7/12*0 = 1.25$, а # 2 может ожидать 1.75 от этой сделки. Таким образом, артиллеристы могут реализовать целый ряд результатов, варьируя шансы, которые улучшают результат, не связанный с кооперацией. Эти результаты составляют область переговоров (см. 2).

Интуитивно может показаться простым, что результатом соглашения между #1 и #2 будет (2,2). Формально это не так просто. Каждый результат, который дает каждому артиллеристу ожидаемую полезность более 1, кажется рационально приемлемым. Какой из них выберут рациональные артиллеристы? В рамках теории переговоров, части теории игр, которая занимается этими проблемами, существует два подхода, которые стремятся ответить на этот вопрос (Binmore 1998, chapter 1). Во-первых, традиционный аксиоматический подход развит в кон-

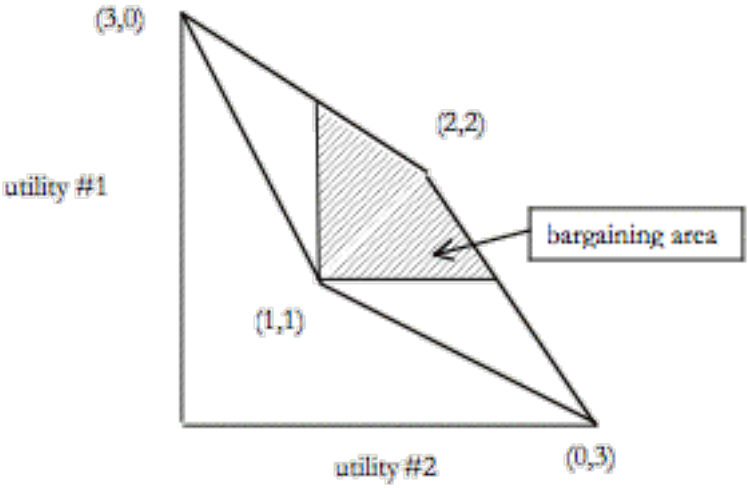

Рис. 2: Bargaining area

тексте кооперативной теории игр. Эта ветвь теории игр предполагает, что, как только рациональные агенты придут к соглашению, они будут ее соблюдать. Задача теоретика состоит в том, чтобы рассмотреть область переговоров и определить, какой результат удовлетворял бы ряду разумных требований рационального исхода переговоров.

Такие вещи, как имена заинтересованных сторон, не должны иметь значения для результата, тогда как их предпочтения имеют значение. Этот подход оказал большое влияние на теорию теоретико-игрового социального контракта. Харсаньи, Роулс, Барри и Готье (Harsanyi, Rawls, Barry, Gauthier) использовали аксиоматические подходы, чтобы оправдать каждый свою версию. Однако, их вердикт в случае с канонирами один и тот же: наиболее рациональный вариант - это распределение, которое дает каждому наводчику ожидаемую полезность, равную 2.

(Обратите внимание, что этот вердикт не сообщает артиллеристам, как им следует реализовать этот результат. Два способа, которыми они могли бы обеспечить ожидаемый результат (2, 2). Они могли бы остаться и сражаться, или они могли бы щелкнуть справедливой монетой, чтобы решить, кто может остаться, а кому разрешено бежать.) *От переводчика: пока не понимаю как можно получить (2,2) если один сбежит, получится либо (0,3), либо (3,0).*

Аксиоматический подход не обращает внимания на структуру процесса переговоров. Все что он требует - чтобы в качестве исходных данных была информация о вознаграждениях сторон. Хотя верно то, что иногда не имеет особого значения, как именно структурируется переговорный процесс, иногда это очень важно. Например, если #1 может подать заявку, а #2 только может принять или отклонить, то #1 скорее всего предложит #2 ожидаемую полезность 1.00001 и оставит за собой 2.99999. Учитывая правила переговорного процесса, #2 придется принять это, так как альтернатива (немного) хуже. С другой стороны, если правила допускают обмен претензиями и предложениями, ситуация совершенно иная. Поэтому, если вы хотите предсказать, каким будет результат переговорного процесса между рациональными агентами, важно знать правила переговоров в деталях, также как и область переговоров. Кроме того, важно знать, будут ли стороны придерживаться соглашения. Ибо, если это не так, маловероятно, чтобы заинтересованные стороны приняли соглашение вместо соглашения, которое окажется обязательным.

Поэтому лучше думать о процессе переговоров как о серии возможных ходов в игре, которая предшествует игре, с которой сталкиваются артиллеристы. Это второй подход, который рассматривает переговорные процессы как игру без сотрудничества. Решение такой игры тогда соответствует решению переговорного процесса. При таком подходе нужно уделять много внимания деталям. Следовательно, анализ является сложным и часто беспорядочным. (Это еще одна причина, почему аксиоматический подход настолько привлекателен для некоторых.)

Тем не менее, вполне возможно, что решение игры и решение, основанное на аксиоматическом подходе, идентичны. На самом деле, это то, чего вы ожидали бы, если предлагаемое аксиоматическое решение вообще правдоподобно. Эта интуиция является движущей силой так называемой программы Нэша (Nash 1950). Эта программа нацелена на оценку аксиоматических решений путем проверки того, приводит ли исход переговорной игры к одному и тому же результату. Успех программы Нэша имеет решающее значение для правдоподобия классических аксиоматических теорий социального контракта. Такие теории рассматривают нравственность как результат (гипотетических) переговоров между идеально рациональными агентами, но не утруждают себя точным указанием, как стороны достигают этого результата. Следовательно, если нет по крайней мере обещания такого детального анализа, как это было обещано по программе Нэша, то результат, который они представляют, не имеет правдоподобности. (более поздние трактовки проблемы переговоров см. Rubinstein 1982 and Binmore 1998). *От переводчика: как я понимаю это возражение касается теории о том что мораль в прошлом была установлена путём переговоров, с моей точки зрения в прошлом явных переговоров не было, но ничего не мешает нам сегодня провести такие переговоры с помощью такой процедуры, которая позволяет сформулировать Парето-оптимальную мораль.*

6 Мораль по соглашению

Одной из самых влиятельных в настоящее время контрактуалистских теорий является теория Дэвида Готье. Однако его теория отличается от других подходов контрактуализма не только в широком использовании теории игр и переговоров, но и в следующем отношении. Одна из трудностей, о которых мы говорили в отношении функционалистического подхода, заключается в том, что он не дает ответа на вопрос «зачем быть мо-

ральным?». Именно здесь контрактная теория Готье отличается от той, которая была у Ролза, Харсаньи и других. Готье не только использует теорию переговоров, чтобы определить, как Ролс и Харсани стремились сделать, содержание фундаментальных моральных принципов. Он также пытается показать, что рациональные агенты будут действовать нравственно. По этой причине мы обсудим его подход более подробно, чем остальные.

Моральная теория Готье, «мораль по соглашению» (Gauthier 1986), является теорией о природе и рациональности морали. (See also Section 3 of the entry on contractarianism). Она состоит из четырех частей. Первая из них - это описание практического разума и естественного состояния человечества, в значительной степени знакомого теоретикам рационального выбора и теоретикам контрактной морали (Gauthier 1986, chapters 2-4). Далее приводится описание принципов поведения, на которые гипотетически соглашались бы рациональные агенты - своего рода «общественный договор» (Gauthier 1986, chapter 5). Третий элемент - спорные ревизионистские рассуждения о практической рациональности, существенный для его аргументации, целью которого является показать, что практически каждый при нормальных обстоятельствах имеет основания принять и соблюдать ограничения, наложенные этими принципами (Gauthier 1986, chapter 6). Наконец, Готье утверждает, что принципы, о которых идет речь, - это принципы морали, аргумент, который делает неявную ссылку на функционалистский подход о моральных нормах (Gauthier 1986, chapters 7-8). Третья часть - ответ Готье на вопрос «зачем быть моральным?». Он затрагивает некоторые очень фундаментальные вопросы в теории игр и теории принятия решений, поэтому мы обсудим это немного позже.

Как понял ещё Гоббс - одно дело, прийти к соглашению и совсем другое дело - выполнить свою часть соглашения. Мораль, по крайней мере, так как она традиционно трактуется, часто требует от нас пожертвовать нашими интересами или целями. Это, по крайней мере на первый взгляд, противоречит тому, что требует рациональность. Ответ Готье заключается в том, что-

бы утверждать, что мы неправильно понимаем практическую рациональность, даже инструментальную рациональность, если считаем, что цель рациональности определяет способ, которым мы должны рассуждать или размышлять. Цель рациональности - делать как можно лучше - не обязательно определяет наш принцип принятия решения - например, выбирать лучшую альтернативу в каждый момент выбора. Что касается концепции максимизации полезности рациональности, которую он принял с недавнего времени (Gauthier, forthcoming), Готье утверждает, что цель максимизации полезности не означает, что мы должны в каждом пункте принятия решения максимизировать полезность. Вместо этого мы должны рассуждать так, чтобы максимизировать полезность. Так же, как иногда бывает, что мы делаем все возможное или, по крайней мере, делаем хорошо, не стремясь делать все лучше и лучше, поэтому иногда может оказаться, что способ максимизирующий полезность в целом не максимизирует полезность в каждой точке принятия решения. Учитывая, что наш способ рассуждения сам влияет на наши перспективы, наши цели или цели иногда лучше всего достигаются без стремления делать все возможное на каждом этапе решения.

Готье в книге «Мораль по соглашению» рассуждает в терминах «намерение на выбор» и, в частности, «принудительной максимизации», намерения сотрудничать с другими участниками даже в обстоятельствах, когда более выгодным является отказ. В более поздней работе Готье развивает свой ревизионистский подход к практической рациональности с точки зрения рациональных планов и намерений и способов рассуждения. Если мы согласны с тем, что агенты могут действовать лучше в любых обстоятельствах, действуя способами, которые не являются «непосредственно максимизирующими», проблема заключается в том, чтобы определить, насколько рациональны такие действия. В книге Готье предполагает, что если наши предпочтения в выборе рациональны, то и наши решения, определенные этими предпочтениями, также рациональны. Ряд теоретиков последовали за Томасом Шеллином, который утверждал, что часто

бывает рационально делать вещи, которые являются иррациональными, но они утверждают, что последние при этих этом не перестают быть иррациональными. Готье полагает, что если курс действия лучше любого другого по его результату, то при определенных условиях он может рационально принять его и проходить его этапы, даже если некоторые из них не являются в момент исполнения, самым лучшим, что можно сделать с точки зрения целей. Поэтому он стремится показать, что, если способ обдумывания или план действий рациональны, то действие согласно нему может быть рациональным, даже если для этого действия требуется делать вещи, которые не являются, рассматриваемые с точки зрения момента действия, оптимальными. Таким образом, если Готье прав, то разумно соблюдать определенные нормы или принципы, даже если они требуют действий, которые не являются лучшими с точки зрения времени действия. Большая часть работ Готье после «Морали по соглашению» развивает и защищает этот ревизионистский подход к практической рациональности. (См. Gauthier 1994, 1996, 1998a и b. For an alternative revisionist account, see McClennen 1990).

Защита Готье принципа «ограниченной максимизации» представляет собой серьезный пересмотр стандартной теории игр и решений. Классическая теория сосредотачивается на рациональности действий в момент выбора. Сам способ рассуждения для выбора выходит за рамки теории. (Вернее, классическая теория выступает в качестве такого способа рассуждения.) Некоторые критики выступали против включения метода рассуждения в область теории (например, Velleman 1997). Однако большинство теоретиков игр утверждают, что если возможно выбрать способ рассуждения, этот выбор сам по себе может быть смоделирован как шаг в более сложной решающей игре, в том числе в предложенной Готье (например, Binmore 1994, Стр. 179-182).

7 Некоторые проблемы контрактуализма

Контрактный подход, включая и теорию Готье, предполагает фундаментальную связь между рациональностью и моралью, как и функционализм. Однако, в отличие от функционалистского подхода, контрактуализм имеет серьёзный аргумент в пользу того, почему это должно быть так. Моральные нормы (или институты, или что-то в этом роде являющееся предметом рассматриваемой теории) рационально приемлемы в соответствии с традицией контрактуализма, только если нет возможного альтернативного соглашения, в котором все заинтересованные стороны были бы в более выгодном положении. Представьте себе, что стороны ведут переговоры о том, какую норму использовать для дележа пирога. Рациональные партии не согласятся с нормой, которая оставит торт на столе впустую. Аналогично с моральными нормами: рациональные агенты не согласятся на норму, которая, как можно ожидать, оставит неиспользованные взаимные выгоды. Поэтому, в соответствии с концепцией морали, принятой в контрактуализме, необходимо, чтобы правильная мораль приводила к результату, эффективному по Парето. По этой причине рациональный выбор в контрактуализме часто рассматривается как ревизионистский по своим последствиям. Утверждение заключается не в том, что здравый смысл или обычная мораль приводят к Парето-эффективным результатам (если они соблюдаются). Вместо этого контрактуализм предполагает что рационально выбирать такие моральные нормы при следовании которым результаты будут Парето-оптимальными.

Критики уже давно утверждают, что неясно, почему результат гипотетического соглашения должен влиять на то, что должны делать агенты вне идеализированных обстоятельств «социального контракта». Некоторые утверждают, что гипотетические контракты (или обещания) не порождают обязательств. Однако это неверное понимание природы этих теорий. Гипотетиче-

ское рациональное соглашение не является обязательным. Скорее, это в первую очередь эвристический механизм, предназначенный для определения характера и содержания взаимовыгодных, справедливых принципов.

Принимая во внимание, что вышеизложенные замечания касаются всех форм контрактуализма, существуют некоторые конкретные проблемы с версиями, которые зависят от теоретико-игровой теории переговоров, как у Готье и других. Наиболее фундаментальным представляется правдоподобность программы Нэша: действительно ли существует рациональное решение всех проблем, связанных с переговорами, которые могут быть указаны и протестированы с использованием теории кооперативов без сотрудничества? Аналогичным образом, как мы можем быть уверены в том, что всегда существует одно единственное решение если проблемы в переговорах до некоторой степени недоопределённы? Множественность возможных решений в переговорах, которая обсуждается в теории переговоров, это плохой знак для таких предположений. Есть основания сомневаться в том, что теоретико-игровой подход к переговорам может действительно помочь нам предсказать исход переговоров рациональных агентов. Как аксиоматический подход, так и подход, не основанный на кооперации, исходят из предположения о том, что существует уникальный, рациональный результат таких переговоров. Хотя это может быть справедливо в некоторых ситуациях, далеко не очевидно, что это всегда так. То есть результат переговоров часто кажется рационально недоопределенным (Sugden 1991). Нерациональные факторы, такие как личные особенности, статус в обществе и т.д., гораздо важнее для определения результата таких переговоров, чем основанные на теории принятия решений и теории игр.

8 Эволюционная теория игр и этика

Существует также еще один вид сомнений, который естественно ведет к третьему крупному движению в теории игр и этике. Контрактуалисты, такие как Готье, понимают фундаментальные нормы, которые управляют нами, исходя из гипотетической ситуации выбора, в которой было бы очень много агентов, вступающих в переговоры по разным принципам или социальным соглашениям. Тем не менее, открыт вопрос, является ли это подходящим способом моделирования процесса рационального выбора, который приводит к появлению морали.

В способе которым теория игр была применена к этике заключается ключевое отличие третьего подхода. Этот третий путь - эволюционная теория игр. Вместо того, чтобы рассматривать мораль как предполагаемый результат сложного крупномасштабного переговорного процесса между полностью информированными и полностью рациональными агентами, эволюционный подход уходит от всех этих предположений. Во-первых, мораль рассматривается как непреднамеренный побочный эффект взаимодействия агентов. Во-вторых, мораль возникает из ряда повторяющихся взаимодействий между небольшими группами агентов (большинство моделей имеют дело только с двумя людьми). Чтобы выразить это в терминах функционализма: мораль - это не решение одной проблемы, а часто повторяющиеся проблемы. В-третьих, вместо того, чтобы предполагать полную информацию и полную рациональность, теория эволюционной игры делает менее требовательные предположения о когнитивных и совещательных навыках агентов. Это может привести к принципиально иным результатам.

Мы можем проиллюстрировать это следующим образом. Руссо описывает состояние природы как нечто похожее на так называемую Оленьи Охоты (Rousseau 1964, p. 166–167). (См. Skyrms 2004 для современной трактовки этой игры.) Представьте двух охотников, которые могут охотиться за зайцем. Их шансы поймать зайца не зависят от действий других. Однако оба предпочи-

тают оленину, но если они будут охотиться на оленя, они будут успешными только в том случае, если каждый выполнит свою часть работы.

		#2	
		stag	*hare*
#1	*stag*	3 3	2 0
	hare	0 2	2 2

Рис. 3: The stag hunt

Предположим, что координаты #1 и #2 (Hare, Hare) т.е. оба охотника поймали зайца. Это равновесие по Парето менее оптимальное чем добыча оленя (Stag, Stag). В то время как выбор по контракту предполагает, что (Stag, Stag) является правильной нормой, на которую стоит остановиться, теория эволюционной игры учит нас, что маловероятно, чтобы равновесие по Парето было выбрано в процессе повторяющихся взаимодействий. Более того, равновесие по Парето нестабильно: случайные отклонения от этого равновесия приведут к тому, что население в целом будет координировать (зайца, зайца), а не (оленя, оленя).

Предположительно это относится к некоторым нашим фактическим нормам - социальным, юридическим или моральным. Они могут быть несовершенными по сравнению с другими нормами, особенно теми, которые выходят из рода идеализирован-

ных ситуаций социального выбора в договорной моральной теории. Однако большинство наших фактических норм зачастую стабильны, и неясно, есть ли у нас основания отходить от них. Поэтому нам остается задаться вопросом, являются ли нормы, выявленные теоретическими теориями ведения переговоров, нормами, приемлемыми для большинства обществ, сообществ и групп. Поскольку «должен» означает «может», у нас есть основания сомневаться в том, что подход, основанный на контрактах, дает нам правильное описание морали, которой мы должны следовать.

До сих пор главным результатом эволюционного подхода является «восстановление» многих существующих моральных интуиций и норм. Таким образом, теоретики эволюционной игры, пишущие об этике (а также моральные философы, использующие эволюционную теорию игр), показали, что среди не вполне рационализированных агентов могут возникать многие нормы координации и сотрудничества, являющиеся объектом исследования более традиционных моральных теорий. (Skyrms, 1996). Кроме того, Skyrms (1996) и другие продемонстрировали, что в противном случае корыстные агенты будут развивать рассудочную эвристику, такую как Золотое правило (поступайте с другими так, как вы хотите быть) И версию «максимизации ограничения» Готье при соответствующих обстоятельствах. То есть, они показывают, что эволюция способствует не только появлению моделей поведения, соответствующих моральным стандартам, но и развитию когнитивной эвристики, которая обладает всеми характеристиками морального мышления.

9 Некоторые замечания к эволюционному подходу

Большинство авторов, которые придерживаются эволюционного подхода, быстро указывают, что этот подход позволяет избежать большей части критики, высказанной в отношении двух

предыдущих подходов. Во-первых, эволюционный подход дает подлинное объяснение возникновения и сохранения моральных норм. Нормы являются непреднамеренным побочным эффектом действий (ограниченно) рациональных агентов и возникают в процессе повторяющихся взаимодействий. В эволюционном подходе «функция» моральной нормы состоит в том, чтобы выбрать устойчивое равновесие в ситуации, когда существует более одного варианта равновесия. Таким образом, устойчивые нормы могут быть неэффективными по Парето. Не существует фундаментальной связи между эффективностью и моралью в эволюционном подходе. Его внимание сосредоточено на равновесии, а не на эффективности. Это также является причиной того, что агент в данной популяции должен следовать этой норме. То есть тот факт, что другие члены населения следуют норме, объясняет, почему индивидуум в данной популяции будет поступать также. Как следствие, эволюционный подход дает ответ на вопрос «Зачем быть моральным?» Следование существующей норме индивидуально рационально. Кроме того, для достижения этого результата не нужно принимать неортодоксальные пересмотры теории выбора, что является большим преимуществом по сравнению с утверждениями Готье о «ограниченной максимизации».

Тем не менее, есть также некоторые основания опасаться успеха эволюционного подхода. Как и в случае с функционалистическим подходом, и в отличие от контрактного проекта, основное внимание уделяется объяснению. Теория эволюционной игры в первую очередь используется для объяснения возникновения и стабильности существующих норм. Он не дает инструментам критического отношения к содержанию этих норм. Он не дает никаких оснований для кодекса поведения как явно морального (однако см. Binmore 1994, 1998).

Эта тенденция особенно тревожна, когда мы видим в литературе эволюцию объяснений поведения для неприятных диспозиций, таких как склонность мужчин к изнасилованию, склонность человека к различиям в статусе по признаку расы и т. П. Поэтому неясно, до какой степени этот подход является альтернативой

существующим моральным теориям. Это, вероятно, лучше всего понимать как форму социальной теории, хотя и противоречивую относительно того, является ли это эмпирически обоснованной теорией или формой априорного теоретизирования (Sugden 2001). Конечно, можно подумать, что эволюционная теория игр не является альтернативой моральной теории, а средством для подрыва или развенчания моральных притязаний. Если источник наших моральных предрассудков и суждений по существу совпадает с упомянутыми выше неприятными склонностями, то, возможно, мы должны сделать вывод о том, что наши моральные суждения ложны или необоснованны, а наши моральные распоряжения недостоверны. Теория эволюционной игры, опираясь на эту интерпретацию, поддержит некий моральный скептицизм (см. Раздел 1 в записи о моральном скептицизме). Некоторые ответы на этот скептицизм можно найти, например, в Gibbard (1990).

10 Некоторые абстрактные следствия использования теории игр в этике

Независимо от достоинств трех подходов, о которых мы говорили выше, есть некоторые замечательные идеи о том, что применение теории игр предлагает моральному теоретику. Как мы уже отмечали выше, существует много игр с несколькими равновесиями. Это особенно характерно для повторных игр конкретных игр, таких как дилемма заключенного. Одним из следствий этого факта является то, что, поскольку эти игры являются полезными представлениями или моделями наших социальных взаимодействий, у нас есть основания ожидать много неопределенности в мире. Как следствие, у нас есть основания опасаться моральных теоретиков, которые заявляют об универсальности и общности в своих конкретных нормативных рекомендациях (Hardin 1988, 2003). *От переводчика: При этом во всем примерах только один вариант равновесия был наилучшим, и нет*

причин не считать нормы приводящие к такому равновесию универсальными

Во-вторых, теория игр ясно показывает, что в любом достаточно большом населении можно ожидать детерминированных сочетаний поведенческих диспозиций. Рассмотрим знаменитую игру Hawk-Dove (Smith 1982):

		agent #2	
		Dove	*Hawk*
agent #1	*Dove*	2 2	3 1
	Hawk	1 3	0 0

Рис. 4: the Hawk-Dove game

Два равновесия в чистых стратегиях в простой игре 2 X 2 являются результатом того, что каждый игрок принимает другую стратегию. Если мы думаем о стратегиях «ястреба» (hawk) и «голубя» (dove), представляющих моральные установки или персонажи, то у нас может быть причина ожидать, что человеческие популяции состоят из агентов, условно говоря, с разными характерами (см. Также Frank 1988; Smith 1982; Skyrms 1996). Более того, с учетом этого анализа далеко не ясно, что теоретик морали в любой ситуации может рекомендовать одно и то же расположение, то есть одну и ту же силу, для всех агентов в этой совокупности: одни должны быть «ястребами», другие -

«голубями» (См. Также Kuhn 2004).

Принимая во внимание, что последние два замечания указывают на оригинальные идеи для моральных теоретиков, мы не можем не упомянуть некоторые критические замечания, которые были сформулированы против применения теории игр к этике. Наиболее фундаментальные из них касаются неявной антропологии рационального агента. Вопрос в том, может ли все, что имеет отношение к моральной теории об агенте, быть захвачено довольно одномерной картиной рационального человека, как это предлагает теория игр. Предполагается, что агент будет полностью охарактеризован его ранжированием предпочтений по результатам и его убеждениям на каждом этапе игры. Тем не менее, морально важные различия, например различия между характерами, не находят места в таком подходе. *От переводчика: С моей точки зрения это спорное замечание, но тут его обсуждать неудобно т.к. вопрос уходит в определение морали и нравственности, по моим определениям для морали индивидуальные особенности не важны, а для нравственности могут иметь значение*

Мы можем проиллюстрировать это беспокойство тем, как понятие репутации используется в моделях альтруистического сотрудничества. Современная теория игр использовала понятие репутации игрока в попытках объяснить сотрудничество в играх с повторяющимися играми, таких как дилемма заключенного (Kreps and Wilson 1982). Однако неясно, что именно означает иметь репутацию в этих контекстах. Обычно репутация - это то, что считается характером человека. В этих моделях, с другой стороны, репутация - это просто история ходов игрока в подобных играх. Между ними существует морально значимая разница. Чему мы верим, когда узнаем, что купец честен? Обычно мы полагаем, что это означает, что он тот человек, который не будет обманывать других, например клиентов, даже в ситуациях, когда это ему выгодно. Почему он так поступает? В то время как другой купец не обманывает, только когда речь не идёт о выгоде, наш купец честен и не обманывает из-за своей честности,

то есть своего характера. Обычно это имеет большое значение в том, как мы будем судить этих двух торговцев. Оба сотрудничают с другими, но только последний заслуживает похвалы за свою честность. Теория игр и теория полезности обычно не имеют места для этого различия (см. Morris 1999). (Релевантность здесь Brennan и Pettit, 2004.) *От переводчика: А как нам узнать что человек честен? Мы же внутрь не можем заглянуть, поэтому его репутация это и есть история его поступков в разных ситуациях, если мы знаем что он поступил честно даже во вред себе, то считаем его честным, хотя нет гарантии что это действительно так, может он случайно так поступил или сознательно накапливает репутацию честного чтобы всех по крупному обмануть - мы не можем судить о честности, можем только говорить о репутации = истории поступков.*

11 Заключение

Большинство современных авторов в этике, которые используют в своей работе теорию игр, являются либо контрактниками, либо эволюционными теоретиками. Эти два подхода представляют собой две различные комбинации теории игр и этики. Традиция контракта, с ее акцентом на полностью рациональных агентов и торга, представляет собой более традиционное использование теории игр. Эволюционный подход, с другой стороны, с акцентом на ограниченные рациональные агенты и повторные взаимодействия, является более недавним прибытием. Большинству экспертов в этой области представляется весьма желательным синтез этих подходов. (Бинмор 1994, 1998 на сегодняшний день является единственной попыткой.)